

Phân khúc khách hàng dựa trên hành vi mua sắm

Project: Customer Segmentation with K-means Clustering

Instructor: **Nguyễn Thái Hà**

TA: Nguyễn Thọ Anh Khoa

STA: Nguyễn Phúc Thịnh

[Source Code](#)

[Link Q&A](#)

Key words:


UCI Online Retail Data Set

KMean

SHAP

Feature Engineering

Executive Summary: Roadmap Pipeline



Notebook 01

Làm sạch & EDA

Notebook 02

Feature Engineering

Notebook 03

K-Means++ Modeling


Notebook 04

SHAP Explainability

✂️ Mỗi notebook nhận output của notebook trước và tạo ra artifact mới. Phải chạy theo thứ tự.

Executive Summary: Key Takeaways

Customer Segmentation for Targeted Retail Marketing



- **Kiến trúc 2 giai đoạn:** tách 179 wholesale-like (4.6%) bằng $SKU_HHI > 0.5$; K-Means++ (k=4) phân 3,741 khách retail.
- **Feature engineering bổ sung RFM:** 14 đặc trưng family-balanced nắm tín hiệu cancellation.
- **Phát hiện lỗi:** C1 1,107 High-Return Actives (29.6%), cancellation rate 25.2% (RFM phân tán nhóm này)
- **4 chân dung hành động được;** mỗi nhóm một chiến lược.
- **Giải thích được:** SHAP quy từng ranh giới cluster về feature cụ thể → biết lý do, không chỉ nhãn.

Phần 1: Giới thiệu & bối cảnh business

Phần 2: EDA & Làm sạch dữ liệu

Phần 3: Feature Engineering: Tư duy & Xây dựng

Phần 4: Mô Hình Clustering K-Means

Phần 5: SHAP Explainability: Mở Hộp Đen

Phần 1: Giới thiệu & bối cảnh business

Phần 2: EDA & Làm sạch dữ liệu

Phần 3: Feature Engineering: Tư duy & Xây dựng

Phần 4: Mô Hình Clustering K-Means

Phần 5: SHAP Explainability: Mở Hộp Đen

BỐI CẢNH

- Một nhà bán lẻ quà tặng online (UK) có **~4,000 khách** và **hơn nửa triệu giao dịch** - dữ liệu rất phong phú nhưng chưa được khai thác tối ưu.
- **Chi phí marketing ngày càng cao**, trong khi **hành vi khách hàng ngày càng đa dạng** - cùng một chiến dịch cho tất cả nghĩa là đúng với vài người và lãng phí với phần còn lại.
- Marketing "**one-size-fits-all**" không còn hiệu quả: tiền chi ra nhiều nhưng không "trúng" ai.

MỤC TIÊU

- **Hiểu sâu khách hàng:** phân tích các pattern ẩn trong dữ liệu giao dịch, ai thực sự đang mua, và mua như thế nào.
- **Tối ưu marketing:** cá nhân hóa chiến lược cho từng nhóm khách hàng thay vì một thông điệp chung.
- Phân khúc khách hàng dựa trên **hành vi mua sắm thực tế** để tối ưu chiến lược CRM, chiến dịch marketing, danh mục sản phẩm và phân bổ ngân sách hiệu quả.

Triệu Chứng

Cùng một thông điệp cho tất cả → sai với hầu hết mọi người

Chi tiết vấn đề

- Cùng 1 email promotional gửi cho toàn bộ ~4,000 khách → tỷ lệ mở thấp, chuyển đổi kém.
- Khách chỉ mua 1 lần bị gửi loyalty discount → lãng phí ngân sách, sai nhu cầu.
- Khách B2B wholesale nhận email về sản phẩm lẻ → không phù hợp, tỷ lệ unsubscribe cao.
- Khách mùa vụ (chỉ mua Q4) bị contact đúng tháng 7 → sai thời điểm, không hiệu quả.
- Khách trả hàng nhiều bị gắn nhãn "bad customer" → bỏ lỡ một nhóm thực chất có tiềm năng cao.

Giải Pháp

Từ "một thông điệp cho tất cả" → "đúng thông điệp cho đúng nhóm"

- Mỗi triệu chứng đều có chung một gốc rễ: **coi mọi khách hàng như nhau**.
- **Phân khúc khách hàng theo hành vi** → mỗi nhóm nhận chiến lược riêng (nội dung, timing, ưu đãi).
- Cách làm trong dự án này 4 bước chính + 1 bước chiến lược:
 - **EDA & Làm sạch**: hiểu dữ liệu thô, loại nhiễu.
 - **Feature Engineering**: dựng 18 đặc trưng hành vi thay cho RFM 3 chiều.
 - **Clustering (K-Means)**: để dữ liệu tự nói lên các nhóm tự nhiên.
 - **SHAP Explainability**: mở hộp đen: vì sao một khách thuộc nhóm đó.
 - **Chiến lược**: mỗi cluster → một hành động marketing cụ thể.

Dataset Thực Tế: UCI Online Retail

Giao dịch thô

541,909

Khách hàng UK

~ 4,000

Tháng dữ liệu

13

Thời gian

Dec 2010
– Dec 2011

Column	Ý nghĩa	Ví dụ	Lưu ý
InvoiceNo	Mã hóa đơn	536365 / C536379	Bắt đầu 'C' = đã hủy
CustomerID	Mã khách hàng	17850	25% missing → loại bỏ
Quantity	Số lượng sản phẩm	6	Âm = điều chỉnh kho → loại
UnitPrice	Đơn giá (£)	2.55	≤ 0 = lỗi → loại
Country	Quốc gia	United Kingdom	Giữ UK only
InvoiceDate	Thời điểm	01/12/2010 08:26	Dec 2010 – Dec 2011

R

Recency

Số ngày từ lần mua gần nhất đến ngày tham chiếu

Thấp = mới mua = tốt

F

Frequency

Số lần mua (distinct invoice) trong toàn bộ lịch sử

Cao = tốt

M

Monetary

Tổng chi tiêu (£) trong toàn bộ lịch sử

Cao = tốt

- **Cách chấm điểm:** với mỗi chiều, chia toàn bộ khách thành 5 bậc (quintile 1–5). Mỗi khách nhận một mã 3 chữ số. Ví dụ **555 = Champion** (mới mua, mua nhiều, chi nhiều); **111 = Lost** (lâu không mua, ít, nhỏ).
- **Vì sao phổ biến?** Ra đời thập niên 1990 cho direct marketing; chỉ cần dữ liệu giao dịch cơ bản (ngày mua, số đơn, doanh thu); **dễ tính, dễ giải thích** cho business → trở thành chuẩn ngành trong CRM.
- Đây là lý do ta dùng RFM làm **baseline** để đối chiếu: liệu feature engineering có thật sự tốt hơn không?

Giới Hạn

RFM thấy "3 con số tổng", không thấy "câu chuyện" hành vi

- **Blind spot 1: Trả hàng nhiều bị chấm điểm oan:** đơn hủy làm giảm cả Frequency & Monetary → RFM tưởng khách kém. Thực tế họ có thể đang *thử mẫu* rồi giữ cái ưng. (VD: Như khách ôm 10 áo vào phòng thử, mua 3 trả 7 → không phải khách tồi)
- **Blind spot 2: Khách mùa vụ bị tưởng "sắp rời bỏ":** khách chỉ mua Q4, đo Recency vào tháng 7 → RFM báo "at-risk". Nhưng đây là nhịp quà tặng định kỳ.
- **Blind spot 3: Không tách được B2B khỏi khách lẻ:** một tiệm nhập sỉ (mua bulk, ít loại SKU) và một người mua quà lẻ có thể ra *cùng điểm RFM*, dù bản chất khác hẳn.
- **Blind spot 4: Chỉ thấy "tổng", không thấy "hình dạng":** RFM không đo nhịp điệu mua (đều vs dồn cục), độ đa dạng giỏ hàng, hay quỹ đạo chi tiêu (đang lên vs đang xuống). (VD: Hai cổ phiếu cùng giá hôm nay - một đang leo dốc, một đang rơi.)

Câu hỏi chiến lược

- ▶ Ai thực sự là khách hàng tiềm năng? (B2B? Retail? Seasonal?)
- ▶ Nhóm nào đang mang lại giá trị LTV cao nhất?
- ▶ Nhóm nào có nguy cơ churn cao nhất?
- ▶ Cần cá nhân hóa chiến dịch như thế nào cho từng nhóm?

Tại sao unsupervised learning?

- ▶ Không có nhãn "loại khách hàng" sẵn có trong dữ liệu
- ▶ Không biết trước có bao nhiêu nhóm tự nhiên
- ▶ Muốn để dữ liệu tự nói lên pattern, không áp đặt giả định
- ▶ Clustering → labels → supervised explainability (SHAP)

4 Giả Thuyết Trước Khi Bắt Đầu Dự Án

H1 Có tài khoản wholesale-like

Dataset mô tả **UK-based online gift retailer with many wholesale customers**. Giả thuyết: ~xx% khách mua bulk, cùng SKU lặp lại, vào giờ hành chính = B2B accounts → cần tách ra TRƯỚC khi cluster để không làm nhiễu retail segments.

H2 Có nhóm khách mua theo mùa vụ Q4 (Seasonal Buyers)

UK gift retailer → Christmas là nguồn doanh thu chính. Giả thuyết: nhóm này tăng đột biến tháng 10–11, gần như vắng mặt 3 quý còn lại → **cần một đặc trưng đo mức độ tập trung chi tiêu theo quý để phát hiện** (Phần 3 sẽ xây dựng feature này).

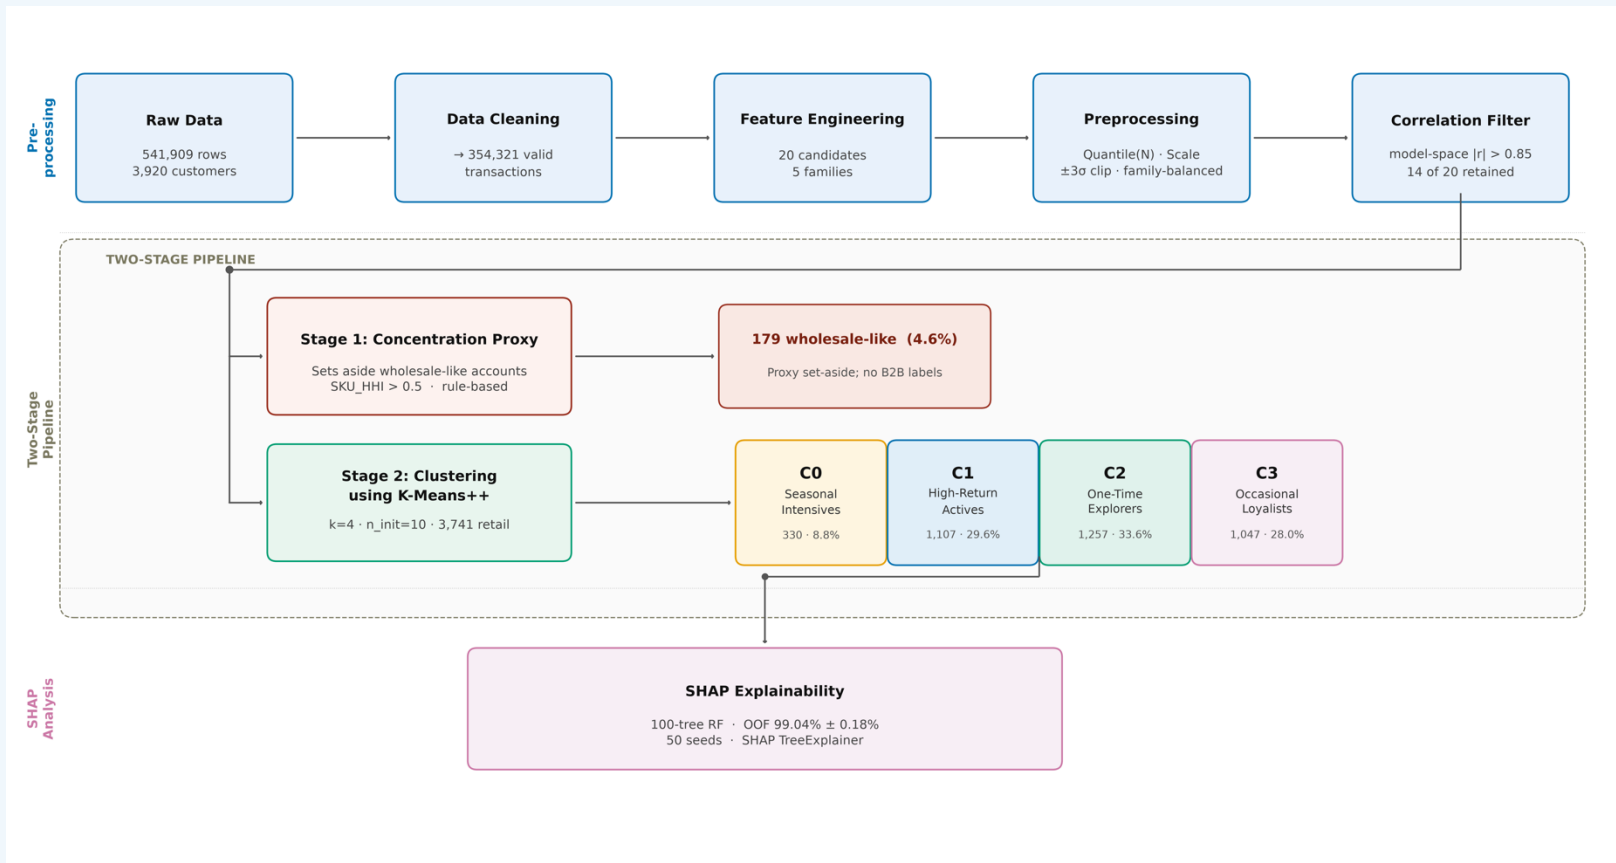
H3 Khách trả hàng nhiều ≠ "bad customers"

Họ đang sample sản phẩm, giữ hàng tốt, trả phần còn lại - pattern của B2B buyer kiểm mẫu. Giả thuyết: High-return customers vẫn có net revenue dương và active liên tục → RFM hoàn toàn bỏ qua signal này.

H4 Phần lớn khách chỉ mua 1 lần - đây là cơ hội bị bỏ qua

E-commerce thường tập trung acquisition hơn retention. Giả thuyết: >30% khách gần như chỉ mua đúng một lần (số ngày gần bó ≈ 0 - một đặc trưng ta sẽ xây ở Phần 3), cần chiến lược re-engagement riêng → one-time buyers là một nhóm thật, không phải noise.

Roadmap Pipeline: 4 Bước



Notebook 01

Làm sạch & EDA

Notebook 02

Feature Engineering

Notebook 03

K-Means++ Modeling

Notebook 04

SHAP Explainability

✂ Mỗi notebook nhận output của notebook trước và tạo ra artifact mới. Phải chạy theo thứ tự.

Phần 1: Giới thiệu & bối cảnh business

Phần 2: EDA & Làm sạch dữ liệu

Phần 3: Feature Engineering: Tư duy & Xây dựng

Phần 4: Mô Hình Clustering K-Means

Phần 5: SHAP Explainability: Mở Hộp Đen

Nhận diện các loại "noise" trước khi làm sạch

InvoiceNo	CustomerID	Quantity	UnitPrice	Country	Vấn đề
C536379	17850	-1	2.55	UK	Đã hủy + Qty âm
536381	NaN	6	3.39	UK	Không có CustomerID
536400	12345	2	0.00	UK	UnitPrice = 0
536500	99999	500	1.25	Germany	Không phải UK
536365	17850	6	2.55	UK	✓ Hợp lệ

- **InvoiceNo = "C536379"**: bắt đầu C → cancelled invoice, Quantity âm.
- **CustomerID = NaN**: 25% dòng không có CustomerID → không theo dõi được hành vi.
- **UnitPrice = 0.00**: giao dịch thử nghiệm nội bộ, không phải mua thật.
- **Country = Germany**: khách nước ngoài mua wholesale định kỳ → hành vi khác biệt hoàn toàn.
- **Quantity âm mà InvoiceNo không bắt đầu C**: điều chỉnh tồn kho nội bộ.

6 Quyết Định Làm Sạch

#	Vấn đề	Hành động	Lý do
1	InvoiceNo bắt đầu 'C'	Loại bỏ	Không phản ánh hành vi mua thật sự
2	Không có CustomerID	Loại bỏ	Không thể theo dõi hành vi theo thời gian
3	Country $\neq$ United Kingdom	Giữ UK only	Khách nước ngoài mua bulk định kỳ — khác biệt
4	Quantity ≤ 0	Loại bỏ	Điều chỉnh tồn kho, không phải giao dịch thật
5	UnitPrice ≤ 0	Loại bỏ	Mục nhập thử nghiệm hoặc lỗi hệ thống
6	Khách mua < 2 lần	Giữ lại	One-time buyers là phân khúc thật, không phải noise

⚠ **Lưu ý:** bước 1 bỏ giao dịch hủy, nhưng Notebook 02 vẫn tính tỷ lệ hủy ([ReturnRate](#)) như một feature!


Sau khi cleaning-mỗi bước bị loại bao nhiêu?

Bước	Số dòng còn lại	Loại đi
Dữ liệu gốc	541,909	—
Bỏ cancelled ('C')	532,621	−9,288 (−1.7%)
Giữ UK only	487,622	−44,999 (−8.3%)
Bỏ missing ID	354,345	−133,277 (−24.6%)
Lọc Qty & Price > 0	354,321	−24

Kết quả: 354,321 dòng hợp lệ → tổng hợp về 3,920 khách hàng .

Bước loại nhiều nhất là **bỏ missing CustomerID** (25% dòng raw không có ID).

Revenue spike Q4 → gợi ý một đặc trưng theo mùa vụ




Pattern phát hiện: Doanh thu tháng 11 và 12 cao đột biến so với các tháng còn lại trong năm. Tháng 10 cũng cao đáng kể: khách chuẩn bị hàng Giáng sinh sớm. Tháng 1–2: thấp nhất (post-holiday slowdown)

Diễn giải: Đây là **retailer đồ quà tặng** mua sắm cuối năm (Giáng sinh, Tết dương lịch) là hành vi đặc trưng

Từ pattern → ý tưởng feature: nếu cả cửa hàng dồn doanh thu vào Q4, hẳn có những khách chỉ mua vào mùa này. → gợi ý cần một đặc trưng đo tỷ lệ chi tiêu tập trung vào một quý của mỗi khách.

Giao dịch giờ hành chính ngày thường → B2B signal




Phát hiện: Giao dịch tập trung vào 9h–17h, thứ 2–6. Cuối tuần và tối rất ít giao dịch.

Diễn giải: Một phần đáng kể khách hàng **không phải retail consumer** ▶ họ là doanh nghiệp nhỏ đặt hàng trong giờ làm việc

Hệ quả: Cần phân biệt B2B khỏi B2C trước khi clustering → tránh tạo nhóm "nhân tạo" do sự khác biệt B2B/B2C

Từ pattern → ý tưởng feature: các tín hiệu "mua sỉ, giờ hành chính, tập trung ít loại SKU" này sẽ được lượng hoá thành đặc trưng B2B ở Phần 3

Long-tail spending → cần QuantileTransformer



- **Pattern:** Median chi tiêu ~£300. Top 1% khách hàng chi tiêu >£10,000 **gấp 30x trung vị**
- **Vấn đề với K-Means:** Dùng Euclidean distance trên dữ liệu lệch → outlier kéo centroid lệch, ảnh hưởng toàn bộ clustering
- **Giải pháp:** QuantileTransformer - chuyển phân phối lệch thành phân phối chuẩn trước khi clustering

R

Recency

Số ngày từ lần mua gần nhất đến ngày tham chiếu

Thấp = mới mua = tốt

F

Frequency

Số lần mua (distinct invoice) trong toàn bộ lịch sử

Cao = tốt

M


Monetary

Tổng chi tiêu (£) trong toàn bộ lịch sử

Cao = tốt

- ▶ Recency: Số ngày kể từ lần mua cuối (tính đến 2011-12-31). Thấp = tốt
- ▶ Frequency: Số invoice hợp lệ của khách. Cao = tốt
- ▶ Monetary: Tổng doanh thu từ khách ($Qty \times UnitPrice$). Cao = tốt
- ▶ RFM segments cơ bản: Champions (R cao, F cao, M cao), At-Risk, Lost, New Customers...
- ▶ Dùng RFM làm baseline để so sánh: feature engineering có tốt hơn không?

Bản đồ 10 phân khúc RFM



- **Bản đồ phân khúc:** Recency (x) × Frequency/Monetary (y) → **10 phân khúc chuẩn** (Champions, Loyal, At Risk, Hibernating...).
- Góc trên-trái = khách tốt nhất (mới mua, mua nhiều); góc dưới-phải = khách nguội lạnh.
- Dùng RFM làm **baseline**: feature engineering có tốt hơn không?

Phần 1: Giới thiệu & bối cảnh business

Phần 2: EDA & Làm sạch dữ liệu

Phần 3: Feature Engineering: Tư duy & Xây dựng

Phần 4: Mô Hình Clustering K-Means

Phần 5: SHAP Explainability: Mở Hộp Đen

Triết Lý: Mỗi Feature Kể Một Câu Chuyện

"Đừng hỏi feature này ĐO Gì. Hỏi: feature này cho ta biết điều gì về hành vi khách hàng?"

- ▶ **20 features** được đề xuất → **14 features** sau khi lọc tương quan Pearson
- ▶ **5 nhóm = 5 góc nhìn** khác nhau về cùng một khách hàng
- ▶ Mỗi nhóm trả lời một câu hỏi kinh doanh cụ thể
- ▶ Features không tự nhiên xuất hiện - phải được **thiết kế từ domain knowledge**

5 Nhóm Features — 5 Góc Nhìn Về Khách Hàng

Nhóm	Câu hỏi	Candidate
Purchase Rhythm	"Mua theo nhịp nào?"	4
Spending Shape	"Chi tiêu ra sao?"	5
Basket Behaviour	"Mua gì mỗi lần?"	3
Volume & Bulk	"Có phải B2B?"	5
Customer Lifecycle	"Vô hình với RFM?"	3
Tổng cộng: $4+5+3+5+3 = 20$ candidates → sau khi lọc tương quan trong model space còn 14 features .		

- **Recency (Độ mới của lần mua gần nhất):** số ngày từ lần mua gần nhất đến ngày tham chiếu. Thấp = mới mua gần đây.
- **InterPurchaseCV (Hệ số biến thiên khoảng cách giữa các lần mua):** CV (std/mean) của khoảng cách giữa các lần mua. $CV \approx 0$ = mua đều đặn, CV cao = mua ngẫu hứng.
- **ActiveSpanDays (Số ngày gắn bó):** ngày cuối – ngày đầu mua. Khách mua 1 lần $\rightarrow 0$. Khách gắn bó 1 năm $\rightarrow 365$.
- **MonthlyOrderRate (Tần suất đặt đơn theo tháng):** số đơn / (ActiveSpanDays/30). Chuẩn hóa tần suất theo thời gian thực sự hoạt động, tránh thiên lệch cho khách mới.

CV = std / mean — một con số nói lên tính nhất quán

CV $\approx$ 0 — Điều đặn theo lịch



Khoảng cách giữa các đơn hàng gần như bằng nhau. **Dấu hiệu B2B** hoặc habit mua hàng mạnh

CV cao — Ngẫu hứng



Khoảng cách biến động lớn. Mua khi có nhu cầu phát sinh, không theo lịch định sẵn

Tại sao CV tốt hơn std? Std phụ thuộc vào scale. Khách mua mỗi 7 ngày ± 1 ngày vs mỗi 30 ngày ± 4 ngày — CV cho thấy cả hai đều khá đều đặn (14% vs 13%).

- **AOV (Average Order Value-Giá trị đơn hàng trung bình):** tổng chi tiêu / số hóa đơn hợp lệ. Đo "mỗi lần mua tốn bao nhiêu" khác Monetary (tổng) vì không bị lệch bởi tần suất.
- **SpendGini (Hệ số Gini chi tiêu):** hệ số Gini của phân phối chi tiêu theo hóa đơn. Cao = có 1,2 lần mua khổng lồ chiếm phần lớn.
- **PriceCV (Hệ số biến thiên đơn giá):** CV của UnitPrice các mặt hàng đã mua. Cao = mua cả đồ rẻ lẫn đắt - đa dạng danh mục.
- **MaxSpendShare (Tỷ trọng hóa đơn lớn nhất):** hóa đơn lớn nhất / tổng chi tiêu. = 1.0 → toàn bộ tiền trong một lần mua duy nhất.
- **SpendAcceleration (Gia tốc chi tiêu):** (TB chi tiêu 3 tháng cuối – TB 3 tháng đầu) / TB 3 tháng đầu, clip $[-3, 3]$. Dương = đang mua nhiều hơn, âm = đang giảm dần.

Hệ số Gini — từ bất bình đẳng thu nhập đến chi tiêu retail

Gini trong kinh tế

- ▶ Gini = 0: Mọi người thu nhập bằng nhau (bình đẳng hoàn toàn)
- ▶ Gini = 1: Một người có tất cả (bất bình đẳng tuyệt đối)

Gini trong retail

- ▶ Gini thấp: Chi tiêu phân bổ đều qua các hóa đơn
- ▶ Gini cao: Có 1–2 "siêu hóa đơn" chiếm phần lớn chi tiêu

Giải thích trực quan: Khách A: 10 hóa đơn $\times$ £100 $\rightarrow$ SpendGini $\approx$ 0. Khách B: 1 hóa đơn £900 + 9 hóa đơn $\times$ £11 $\rightarrow$ SpendGini $\approx$ 0.8. Cùng *tổng* chi tiêu, nhưng pattern khác nhau hoàn toàn

TẠI SAO FEATURE NÀY CÓ GIÁ TRỊ?

SpendGini cao kết hợp MaxSpendShare cao $\rightarrow$ khách có "ngày mua lớn" $\rightarrow$ có thể là seasonal buyer (C0) hoặc B2B kiểm hàng mẫu.

- **NewSKURate (Tỷ lệ sản phẩm mới):** tỷ lệ sản phẩm mới trong mỗi lần mua. = 1.0 → luôn mua SKU chưa từng mua (**Explorer**). = 0 → chỉ mua lại SKU cũ (**Loyalist**).
- **RepeatSKUFraction (Tỷ lệ mua lại SKU đã từng mua):** tỷ lệ dòng hàng thuộc SKU đã xuất hiện ở hóa đơn trước. Bổ sung cho NewSKURate - đo mức độ trung thành với sản phẩm cụ thể; ít bị lệch bởi khách mua 1 lần.
- **BasketSizeCV (Hệ số biến thiên kích thước giỏ hàng):** CV của số SKU mỗi giỏ hàng. Cao = có lúc mua 1 sản phẩm, có lúc mua 30 - hành vi không nhất quán.
- **MedianBasketQty (Số lượng trung vị mỗi giỏ):** trung vị tổng số đơn vị mỗi hóa đơn. Cao = thường mua số lượng lớn (dấu hiệu bulk buyer).

- **BurstIndex (Chỉ số dồn chi tiêu vào một hóa đơn):** $\text{max}(\text{chi tiêu một hóa đơn}) / \text{mean}(\text{chi tiêu mỗi hóa đơn}) = \text{số hóa đơn} \times \text{MaxSpendShare}$. = 1.0 khi mọi hóa đơn bằng nhau (hoặc chỉ có 1 hóa đơn).
- **BulkLineRate (Tỷ lệ dòng hàng mua sỉ):** tỷ lệ dòng hàng có Quantity ≥ 12 . Cao $\rightarrow$ mua số lượng lớn $\rightarrow$ tín hiệu B2B mạnh.
- **QuantityCV (Hệ số biến thiên số lượng):** CV của số lượng đặt mỗi dòng hàng. Thấp = luôn đặt cùng số lượng (B2B-like định kỳ).
- **SKU_HHI (Chỉ số tập trung danh mục sản phẩm):** Herfindahl-Hirschman Index theo SKU. Cao = tập trung vào 1–2 loại sản phẩm $\rightarrow$ B2B signal mạnh nhất.

Herfindahl-Hirschman Index — đo mức độ tập trung

HHI trong kinh tế

- ▶ $HHI = \sum(\text{market_share}^2)$
- ▶ $HHI = 1.0 \rightarrow$ độc quyền (1 công ty 100%)
- ▶ HHI thấp $\rightarrow$ cạnh tranh nhiều bên
- ▶ Được OECD dùng để kiểm tra sáp nhập

SKU_HHI trong retail


- ▶ $HHI = \sum(\text{revenue_SKU}/\text{total_revenue})^2$
- ▶ $HHI \approx 1.0 \rightarrow$ chỉ mua 1–2 loại sản phẩm
- ▶ HHI thấp $\rightarrow$ mua đa dạng nhiều loại
- ▶ **$HHI > 0.5 \rightarrow$ B2B signal**

VÍ DỤ B2B VS RETAIL

Tiệm hoa: 80% doanh thu từ "bình hoa đỏ size M" $\rightarrow$ $SKU_HHI \approx 0.64 \rightarrow$ B2B/wholesale buyer

Khách retail: Mua 20 loại đồ lưu niệm khác nhau $\rightarrow$ $SKU_HHI \approx 0.05 \rightarrow$ retail consumer

Wholesale-like: vì sao tách trước?



179 tài khoản wholesale-like (4.6%) đặt sang một bên trước clustering

✗ Giữ proxy trong K-Means

✓ Lọc rule-based

Toàn bộ 3,920 khách →
Silhouette **0.177**

Cohort 3,741 khách →
Silhouette **0.244**

Nguyên tắc: Khi nào dùng **rule-based** thay vì ML? → Khi tín hiệu rõ ràng, có domain knowledge, và minority class đủ nhỏ để bị "chìm" trong ML.

- **ReturnRate (Tỷ lệ hủy đơn theo số lượng):** (số hóa đơn cancelled) / tổng hóa đơn. **Feature quan trọng nhất trong mô hình** (SHAP sẽ chứng minh).
- **ReturnValueRate (candidate):** tổng giá trị cancelled / tổng giá trị gross. Candidate này chỉ dùng trong sensitivity analysis vì tương quan Spearman 0.971 với ReturnRate.
- **QuarterConcentration (Mức độ tập trung chi tiêu theo quý):** chi tiêu quý cao nhất / tổng chi tiêu cả năm, clip [0.25, 1.0].
 - Cao ($\rightarrow 1.0$) = dồn gần hết vào 1 quý (seasonal buyer); 0.25 = trải đều 4 quý.
 - Đây chính là feature hiện thực hoá pattern doanh thu dồn Q4

Chuẩn bị features cho K-Means — thứ tự quan trọng

1

QuantileTransformer (output='normal')

Chuyển phân phối lệch → normal distribution. Ví dụ: điểm phân vị thay cho điểm tuyệt đối. Không dùng Box-Cox vì có features có nhiều giá trị 0 (ReturnRate của khách không trả hàng).

2

StandardScaler → z-score (mean=0, std=1)

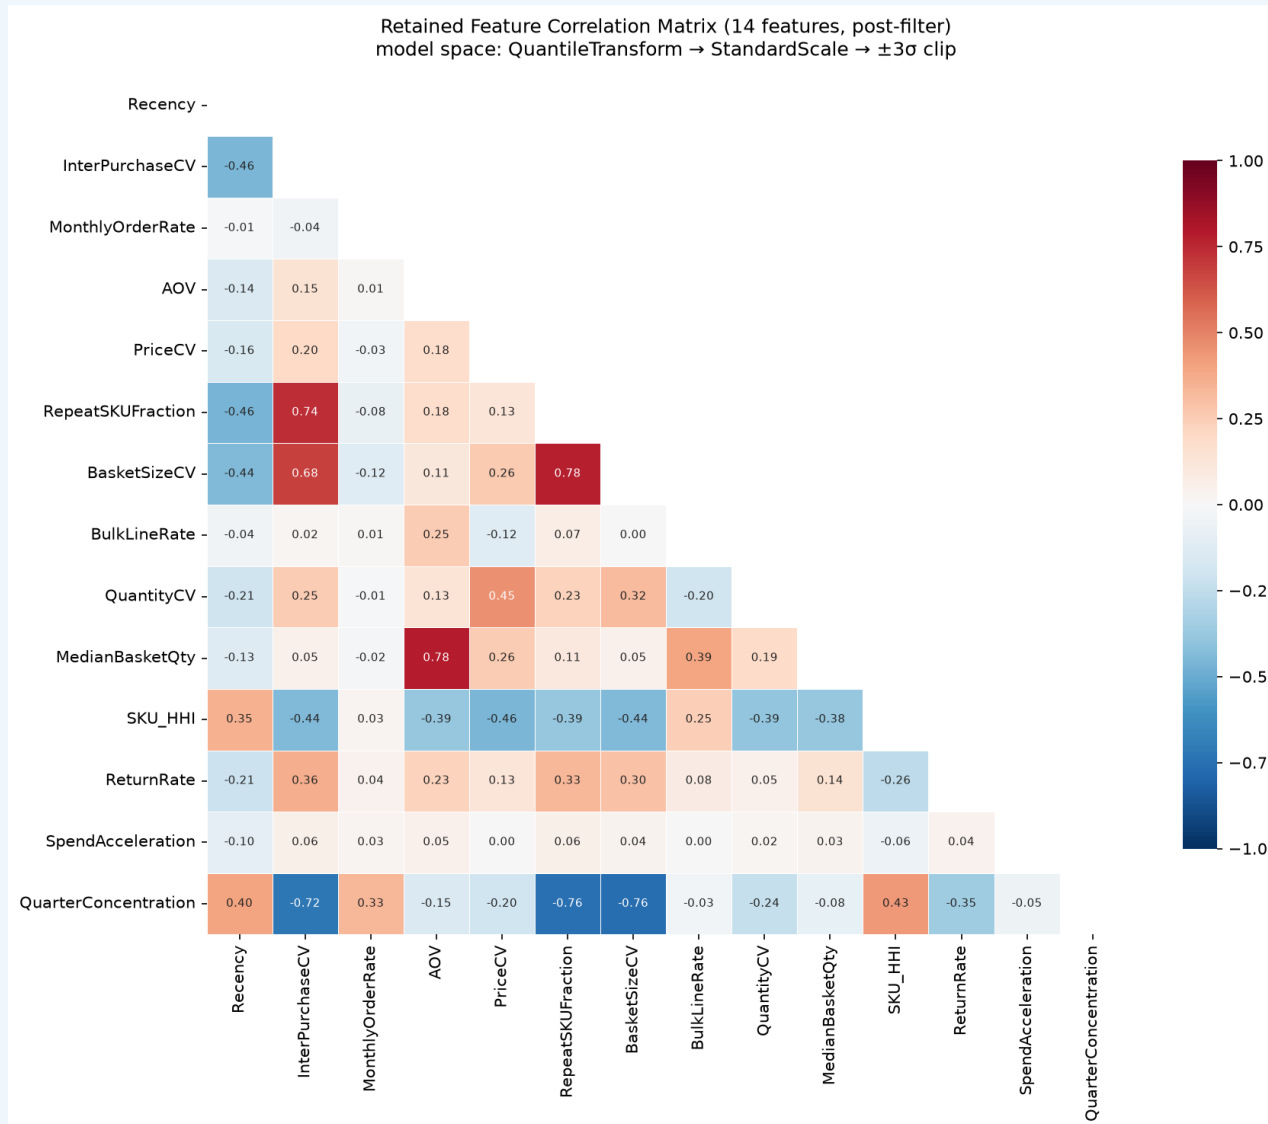
K-Means dùng Euclidean distance — mọi features phải cùng thang đo. Không scale → feature có giá trị lớn (chi tiêu £) chi phối khoảng cách.

3

$\pm 3\sigma$ Clipping

Sau khi scale, outlier B2B có z-score $\approx 4+$. Clipping kiểm soát ảnh hưởng mà không xóa khách hàng. Giữ thông tin, giảm tác động extreme.

Lọc tương quan: 20 → 14 features



Tại sao lọc tương quan?

- Nếu hai features tương quan cao ($|r| > 0.85$), chúng "kể cùng một câu chuyện".
- K-Means sẽ "nghe" điều đó **hai lần** → méo mó khoảng cách.
- **Bị loại (6 features):** ReturnValueRate (Spearman 0.971 với ReturnRate), SpendGini, MaxSpendShare, BurstIndex, ActiveSpanDays, NewSKURate-quá tương quan hoặc tín hiệu trùng.
- **Được giữ (14 features):** bao gồm AOV và RepeatSKUFraction từ Spending Shape và Basket Behaviour.
- **Kết quả:** 14 features, max absolute model-space correlation = 0.781.

Phần 1: Giới thiệu & bối cảnh business

Phần 2: EDA & Làm sạch dữ liệu

Phần 3: Feature Engineering: Tư duy & Xây dựng


Phần 4: Mô Hình Clustering K-Means

Phần 5: SHAP Explainability: Mở Hộp Đen

Unsupervised Learning cung cấp nhiều phương pháp tiếp cận phân cụm, mỗi phương pháp có ưu điểm riêng phù hợp với từng loại dữ liệu và yêu cầu business.


K-means

Phân cụm dựa trên khoảng cách Euclidean, tối ưu WCSS. **Nhanh, đơn giản, dễ diễn giải.**




DBSCAN

Phân cụm dựa trên mật độ, tự động phát hiện outliers. Phù hợp với **cụm hình dạng bất thường**.




Hierarchical Clustering

Xây dựng cây phân cấp (dendrogram), không cần chọn k trước. Hữu ích cho **phân tích cấu trúc lồng nhau**.



Gaussian Mixture

Mô hình xác suất, cho phép điểm thuộc nhiều cụm với độ tin cậy khác nhau. Phù hợp **cụm chồng lấn**.



Lựa chọn trong dự án: K-means vì tính đơn giản, hiệu quả tính toán cao, và khả năng diễn giải centroid rõ ràng cho business users.

K-means là thuật toán phân cụm phổ biến nhất, chia dữ liệu thành k cụm sao cho các điểm trong cùng cụm có khoảng cách gần nhau nhất, và xa các cụm khác nhất.

Mục tiêu tối ưu

Tối thiểu **WCSS (Within-Cluster Sum of Squares)** - tổng bình phương khoảng cách từ mỗi điểm đến centroid của cụm chứa nó.
Minimize WCSS:


$$J = \sum_{i=1}^k \sum_{x \in C_i} ||x - \mu_i||^2$$

Cơ chế lặp

Khởi tạo k centroids ngẫu nhiên → Gán điểm vào cụm gần nhất → Cập nhật centroid → Lặp lại cho tới hội tụ. Sử dụng khoảng cách **Euclidean**.

Chọn số cụm k

Sử dụng **Elbow Method** (quan sát điểm "gối") và **Silhouette Score** (đo độ tách biệt).



Ưu điểm nổi bật

- ✓ **Đơn giản & trực quan:** Dễ hiểu, dễ giải thích cho business users
- ✓ **Hiệu suất cao:** Tốc độ nhanh, mở rộng tốt với dữ liệu lớn (**O**)
- ✓ **Centroid rõ ràng:** Dễ dàng diễn giải đặc trưng trung bình của từng cụm
- ✓ **Phù hợp dữ liệu cân bằng:** Hoạt động tốt khi cụm có kích thước và hình dạng tương đối đều

Hạn chế & cách khắc phục

- ✗ **Cần chọn k trước:** Khắc phục bằng Elbow + Silhouette
- ✗ **Nhạy với outliers:** Khắc phục bằng Box-Cox transformation
- ✗ **Nhạy với khởi tạo:** Khắc phục bằng n_init=10 (chạy nhiều lần)
- ✗ **Giả định cụm "đều":** Khắc phục bằng chuẩn hoá + scale dữ liệu

Metric trực quan nhất: "Tôi thuộc về cluster này đúng không?"

$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

- ▶ **a(i):** Khoảng cách trung bình từ điểm i đến các điểm *trong cùng cluster*. Nhỏ = gắn kết tốt với cluster của mình
- ▶ **b(i):** Khoảng cách trung bình đến cluster *lân cận gần nhất*. Lớn = xa cluster khác
- ▶ **Phạm vi:** $[-1, 1]$. Gần 1 = tốt. ≈ 0 = nằm ở ranh giới giữa 2 cluster. Âm = bị phân nhóm sai

VÍ DỤ LIÊN TƯỞNG

Trong tiệc đứng: Silhouette cao = bạn biết rõ mình thuộc nhóm bạn bè nào (nhóm đứng sát nhau, các nhóm đứng xa). Score thấp = đứng giữa hai nhóm, không biết thuộc về đâu.

Hai metrics bổ sung cho Silhouette

Davies-Bouldin Index (DB) — thấp = tốt


DB = trung bình của: (đường kính cluster A + đường kính cluster B) / khoảng cách giữa A và B — đo xem cluster có "gọn và xa nhau" không. Ví dụ: 4 thành phố trên bản đồ — DB thấp = vùng đô thị nhỏ gọn và các thành phố xa nhau.

Calinski-Harabasz Index (CH) — cao = tốt

CH = $(SS_Between \times (n-k)) / (SS_Within \times (k-1))$ — tỷ lệ "tín hiệu giữa cluster" / "nhiều trong cluster". Ví dụ: SNR trong âm thanh — CH cao = nhạc to (tín hiệu giữa cluster rõ) và tiếng ồn nền nhỏ.

Composite Score: $0.5 \times \text{Silhouette} + 0.25 \times (1/(1+DB)) + 0.25 \times (CH/CH_max)$. Silhouette trọng số gấp đôi vì nó trực quan nhất về chất lượng geometric.


K-Sweep: Kết Quả Chọn k



- Silhouette score cao nhất tại **k=2** (0.315) → metric thống kê tốt nhất.
- Nhưng k=2 chỉ phân biệt "mua nhiều" vs "mua ít" → quá thô để ra chiến lược marketing.
- Composite score cho thấy k=3 và k=4 cạnh tranh nhau (k=4: Sil 0.244, DB 1.764, CH 1066).
- Quyết định cuối cùng cần lập luận **business**, không chỉ dựa vào metric.


Tại sao k=4? Từ thống kê đến hành động

K-Means k=3 vs k=4 — Retail Cohort (n=3,741)



- Về mặt thống kê thuần, k=2 có Silhouette cao nhất → **nhưng không đủ độ phân giải để hành động.**
 - Điều gì xảy ra khi k=3 → k=4?
 - k=4 cho 4 chân dung khách hàng có thể hành động được, mỗi nhóm gắn với một chiến lược marketing riêng.
- Chọn **k=4**: cân bằng giữa chất lượng geometric và giá trị business (actionability).


k=3 → k=4 tách ra nhóm nào?




- **k=3 → k=4** tách riêng **nhóm khách mua dồn vào Q4** thành cluster độc lập
- Nhóm mua-dồn-Q4 vốn bị trộn ở k=3, đến k=4 mới hiện rõ (Hình bên phải đặt tên đầy đủ 4 cluster).

Kết Quả Phân Cụm: 4 nhóm đại diện cho chân dung khách hàng

Retail cluster profiles across 14 retained behavioural features



Descriptive normalised cluster profiles



CLUSTER 0

Seasonal Intensives

Chỉ tiêu tập trung Q4, QuarterConcentration cao, mua dồn dập theo mùa

Chiến dịch trước mùa vụ + loyalty program quanh năm

CLUSTER 2

One-Time Explorers

Mua 1 lần, ActiveSpanDays=0, NewSKURate=1.0

Re-engagement với category trigger; không dùng discount chung

CLUSTER 1

High-Return Actives

Tỷ lệ trả hàng cao — đang thử nghiệm sản phẩm, active buyer

Cải thiện thông tin sản phẩm; không phạt họ

CLUSTER 3


Occasional Loyalists

Gần bỏ lâu dài, rất ít trả hàng, mua thỉnh thoảng — LTV cao nhất

Không làm phiền; nuôi dưỡng nhẹ nhàng

Giả thuyết và kết quả 4 cluster xác nhận điều gì?

RFM labels distribute across the four behavioural clusters



H1 Có khách hàng B2B ẩn trong dataset "retail"

179 tài khoản (4.6%) được đặt sang một bên bằng proxy $SKU_HHI > 0.5$; chưa có B2B ground truth

H2 Có nhóm khách mua theo mùa vụ Q4 (Seasonal Buyers)

C0 Seasonal Intensives: chi tiêu dồn Q4, QuarterConcentration cao

H3 Khách trả hàng nhiều ≠ "bad customers"

C1 — High-Return Actives: trả hàng cao nhưng vẫn active — nhóm RFM bỏ sót

H4 Phần lớn khách chỉ mua 1 lần - đây là cơ hội bị bỏ qua

C2 — One-Time Explorers: $ActiveSpanDays \approx 0$, là cluster thật chứ không phải noise

Phần 1: Giới thiệu & bối cảnh business

Phần 2: EDA & Làm sạch dữ liệu

Phần 3: Feature Engineering: Tư duy & Xây dựng

Phần 4: Mô Hình Clustering K-Means

Phần 5: SHAP Explainability: Mở Hộp Đen

"Khách này thuộc C1, nhưng tại sao?"

- **K-Means output:** Nhãn cluster (0, 1, 2, 3) cho mỗi khách hàng. Không có "feature importance" tự nhiên
- **Vấn đề với marketing team:** Muốn biết *lý do*, không chỉ nhãn. "Khách này thuộc C1 vì ReturnRate cao hay vì ActiveSpanDays thấp?"
- **Vấn đề với mô hình:** Không biết feature nào thực sự tạo ra cấu trúc cluster → không thể cải thiện feature engineering

Giải pháp: Surrogate Model → train một mô hình có thể giải thích được (Random Forest) để mô phỏng lại K-Means, sau đó dùng SHAP trên RF

4 bước biến K-Means thành mô hình có thể giải thích


- 1 Dùng **nhãn cluster K-Means** như nhãn phân loại (classification labels: 0, 1, 2, 3)
- 2 Train **Random Forest Classifier** để dự đoán nhãn cluster từ 18 features
- 3 Áp dụng **SHAP TreeExplainer** trên Random Forest để hiểu tại sao RF đưa ra quyết định đó
- 4 Feature quan trọng với RF = **feature tạo ra cấu trúc cluster** thật sự

- **Bài toán gốc (Lloyd Shapley, 1953):** Trong nhóm người hợp tác tạo ra giá trị, mỗi người đóng góp bao nhiêu? → Giải Nobel Kinh tế 2012
- **Shapley value:** Đóng góp biên tế trung bình của một "người chơi" qua *tất cả* tổ hợp có thể của nhóm
- **Trong ML:** SHAP value của feature *ReturnRate* cho dự đoán "thuộc C1" = đóng góp biên tế trung bình của *ReturnRate* qua tất cả tổ hợp features
- **SHAP TreeExplainer:** Khai thác cấu trúc cây quyết định của Random Forest để tính Shapley values **chính xác và nhanh** - thay vì exponential nếu brute force

VÍ DỤ 3 KỸ SƯ

Kỹ sư A, B, C cùng phát triển sản phẩm bán 1 tỷ đồng. Shapley tính: A một mình → bao nhiêu? A+B → bao nhiêu? B+C → bao nhiêu? Mỗi tổ hợp cho thấy đóng góp biên tế của từng người. Kết quả = phân phối công bằng dựa trên giá trị thực tạo ra.

SHAP Results: Global Importance




Global qua 50 seeds: ReturnRate **24.9% $\pm$ 0.4%**, QuarterConcentration **21.6% $\pm$ 1.1%**, BasketSizeCV **17.8% $\pm$ 0.9%**. Ba feature đầu ~64% importance.

Customer Lifecycle (ReturnRate + QuarterConcentration) chiếm **46.5%** — trực cancellation & mùa vụ là nền tảng cấu trúc.

Surrogate fidelity: OOF accuracy = **0.9904 $\pm$ 0.0018** $\rightarrow$ RF phản ánh rất trung thực K-Means.

SHAP Results: Signed Direction Panel



Diễn giải dấu: SHAP dương → feature đẩy khách vào cluster; âm → đẩy ra.

C1 ReturnRate dấu dương mạnh: tín hiệu trực tiếp của nhóm cancellation-specific.

C0 QuarterConcentration dương: dồn chi tiêu một quý là chữ ký của nhóm.

C0 — Seasonal Intensives

Kích hoạt chiến dịch trước mùa vụ Q4. Loyalty program quanh năm để giảm seasonality. Đừng đánh giá họ bằng Recency trong Q1–Q3.

C1 — High-Return Actives

Cải thiện thông tin sản phẩm, ảnh thực tế, kích thích chi tiết. Không phạt bằng phí hoàn hàng — họ là khách active, đang thử nghiệm.

C2 — One-Time Explorers

Re-engagement với category trigger (gợi ý dựa trên SKU đã mua). Không dùng generic discount — họ tò mò sản phẩm mới, không nhạy với giá.

C3 — Occasional Loyalists

LTV cao, chi phí hỗ trợ thấp nhất. Không làm phiền quá nhiều. Ưu tiên exclusive access, early preview — không cần discount.

Q&A.

Thank you for your attention!